

## – TP 1 – Prétraitement, Régression et Classification

Pour ce TP, vous êtes invités à appliquer de manière pratique : (1) Le prétraitement des données, (2) La régression linéaire & polynomiale, (3) La classification : logistique, KNN et arbre de décision, (4) Les métriques d'évaluation, (5) Les visualisations et l'analyse et (6) les interprétations.

### Préparation de l'environnement de travail


- (1) Ouvrir un notebook ou un éditeur de code sur un dossier séparé (ex : Jupyter, Google Colab, Spyder, ...). Assurer que vous êtes dans un environnement de travail, dossier, séparé de vos autres fichiers.
- (2) Charger le fichier « **data.csv** ». Le fichier sera partagé avec l'énoncé de ce TP.

	age	visits_last_month	time_on_site	is_subscriber	device	engagement	y_true_purchase_amount	y_pred_lin	made_purchase_true	made_purchase_log_pred
1	22	12.0		1	mobile	94.80000000000001	7.9	6.809961340320609	1	1
2	49	4.0	5.1	0	tablet	20.4	0.0	1.1972545566925463	0	0
3	38	7.0	9.1	0	mobile	63.69999999999996	0.0	2.92312997427305	0	0
4	56	10.0	8.1	0	mobile	81.0	10.67	6.4987948681133838	1	1
5	59	7.0	4.8	1	mobile	33.6	9.41	5.708198988943405	1	1
6	34	4.0	9.5	1	mobile	38.0	0.0	2.2456273533426367	0	0
7	58	5.0	16.6	0	desktop	83.0	0.0	4.481465334153591	0	1
8	31	11.0	7.0	0	desktop	77.0	0.0	4.67339012795486	0	1
9	43	11.0	6.2	1	mobile	68.2	9.7	7.367176599787496	1	1
10	44	13.0	8.0	1	desktop	104.0	11.06	9.53171900773364	1	1

### Étape A : Chargement & exploration initiale

Le fichier « **data.csv** » contient des variables numériques et catégorielles, avec quelques valeurs manquantes et bruité.

- (3) Charger le fichier dans un DataFrame avec la méthode : `read_csv()`, de la bibliothèque **pandas**.
  - (4) Afficher les 5 premières lignes et les descriptions statistiques avec les méthodes : `df.head()`, `df.info()`, `df.describe()`.  
 Vérifier et déduire :
    - Types des colonnes : ..... . . . . .
    - Données manquantes : ..... . . . . .
    - Doublons : ..... . . . . .
    - Distribution des valeurs : ..... . . . . .
- ```
RangeIndex: 1000 entries, 0 to 999
Data columns (total 7 columns):
 #   Column      Non-Null Count  Dtype  
--- 
 0   age         1000 non-null   int64  
 1   visits_last_month 970 non-null   float64
 2   time_on_site  970 non-null   float64
 3   is_subscriber 1000 non-null   int64  
 4   device        970 non-null   object 
 5   made_purchase 1000 non-null   int64  
 6   purchase_amount 1000 non-null   float64
dtypes: float64(3), int64(3), object(1)
```
- (5) Créer les Visualisations ci-dessous, utilisant : **Histogrammes** pour chaque variable numérique (**histplot**), **Diagramme en barres** pour device (**countplot**), **Heatmap corrélation** (numériques), **Pairplot** (**seaborn**) pour inspecter les relations entre les différentes variables.



- (6) Détecter valeurs manquantes utilisant la méthode : `df.isna().sum()`.
- (7) Quelles variables semblent corrélées avec « `purchase_amount` » ? .. . . . .
- (8) « `made_purchase` » suit-il la même tendance ? .. . . . .

## Étape B : Prétraitement de données


Pour cette étape, vous êtes invité à suivre les étapes vues durant la séance de cours, et TD de la partie Prétraitement des données. Pour traiter les problèmes vécus dans étape A.

- (9) Appliquer des Imputations pour :
- Les variables numériques : `median` pour `time_on_site`, `visits_last_month`, expliquer pourquoi ? .. . . . .
  - .....
  - Les variables Catégorielles : `mode` pour device, expliquer pourquoi ? .. . . . .
- (10) Appliquer l'approche d'Encodage : « `device` » → `OneHotEncoder`. NB : `is_subscriber` laissé tel quel.
- (11) Créer une méthode de Feature engineering simple : `engagement = visits_last_month * time_on_site`.
- (12) Appliquer une étape de Scaling (Normalisation/standarisation) : `StandardScaler` pour features utilisées par KNN.
- (13) Réaliser les mêmes visualisations de partie A pour justifier les étapes du post-prétraitement : `boxplots` avant/après, distribution de `purchase_amount`.
- (14) Déduire : .. . . . .

## Étape C: Régression (predict `purchase_amount`)

Pour cette étape, vous êtes invité à entraîner et comparer entre la Régression Linéaire et Polynomiale (deg 2). Utiliser les fonctions prédéfinies de la bibliothèque : `sklearn`.

- (15) Séparer les données d'entraînement et testing (80%/20%), utiliser `random_state=42` de la fonction `train_test_split` de la bibliothèque : `sklearn.model_selection`.
- (16) Créer les Features candidates : `age`, `visits_last_month`, `time_on_site`, `is_subscriber`, one-hot device, engagement.
- (17) Entraîner les modèles : `LinearRegression` et `PolynomialFeatures(degree=2)`.
- (18) Évaluer les deux modèles créer utilisant les données de testing, avec les métriques : MAE, MSE, RMSE, R2.
- (19) Créer ces Visualisations utilisant la bibliothèque `matplotlib.pyplot` :
  - Scatter `y_true` vs `y_pred` (pour chaque modèle) avec ligne `y=x`.
  - Residuals plot (résidu vs préd).
  - Learning curve (train/val RMSE en fonction de la taille d'échantillon) — pour voir étudier sur ou underfitting.




- (20) Choisir le modèle le plus adapté à ce jeu de données. Justifier et enregistrer ce modèle pour les prédictions  
 (21) Le polynôme réduit-il erreur ? y a-t-il surapprentissage ? ....



## Étape D: Classification (predict made\_purchase)

Dans cette partie, vous êtes invité à créer des modèles de classification avec un entraînement de Logistic Regression, KNN, Decision Tree. Utiliser les fonctions prédéfinies de la bibliothèque : **sklearn**.

- (22) Choisir les features appropriés pour cette classification :  
 ....
- (23) Créer les partition train/test split identique à la problématique de régression.
- (24) Créer les modèles de classification avec l'Entraînement & prédiction pour chaque modèle :
- LogisticRegression (solver='lbfgs'),
  - KNeighborsClassifier (avec les valeurs k=3,5,7, pour comparer entre ces valeurs),
  - DecisionTreeClassifier (max\_depth=4 et tester)
- (25) Évaluer chaque modèle avec les métrique de la bibliothèque **sklearn.metrics** :
- accuracy, precision, recall, f1\_score
  - matrice de confusion (heatmap)
  - ROC curve + AUC
  - Precision-Recall curve
  - Calibration curve (optionnel, utile pour logistic)
- (26) Créer ces visualisations supplémentaires :
- Importance des features (bar chart) pour l'arbre.
  - Courbe performance (accuracy/F1) en fonction de k pour KNN.
  - Decision boundary visual (sur un sous-ensemble 2D : visits\_last\_month vs time\_on\_site)



- (27) Comparer modèles et justifier choix (préciser tradeoffs: sensibilité vs précision).



- (28) Quel modèle minimiserait les faux négatifs (FN) si l'entreprise veut capturer acheteurs potentiels ? (Réponse: privilégier rappel)  
 (29) Quelle conséquence d'un dataset non normalisé sur KNN ?

## Étape E : Synthèse & Rapport

- (30) Résumer résultats (tableau comparatif des métriques).  
 (31) Visualisations clés à inclure dans le rapport (scatter prédictif vs vrai, ROC, confusion matrices, feature importances).  
 (32) Recommandations business : quel modèle déployer pour régression et pour classification ? pourquoi ?